



游戏不再做歪！AI模拟千名玩家、准确率超85%，用研,测试,买量“省大钱”？

2026-04-22 · 数据/报告

字号

【GameLook专稿，禁止转载！】

GameLook报道/做一款游戏，最难的是什么？

某种意义上讲，不是技术，不是美术，甚至不是钱，而是决策。

据腾讯高级副总裁马晓轶此前接受Gamelook采访时表示，每个3A游戏都有1500个关键决策点，至少做对1200个才能成功。

问题是，这些决策凭什么做？大厂有用户调研团队，有A/B测试资源，有充足预算请真人玩家试玩反馈。而小团队要么抄市场验证过的爆款路线，走换皮捷径；要么靠制作人拍脑袋，赌运气。买量更夸张。为了测试哪个素材效果好，得真金白银往外砸，一个A/B测试跑下来，都能让预算捉襟见肘。

那么，这笔钱，能省吗？

海外已经有创业公司在尝试回答这个问题。比如日本的Alt.ai和Nulltitude.ai等消费者调研公司，开始用AI模拟消费者行为做测试。还有那家因为“斯坦福小镇”出圈的开发团队Simile，转身就拿了1亿美元融资，他们做的事，本质上就是在模拟人类，按照终端用途来看，它可以模拟游戏里的NPC，模拟聊天机器人，也可以模拟用户。

想象一下：你不再需要花钱请大量的真人来填问卷，而是换成算力，让AI替他们回答，这将节约多少用户调研资金、游戏研发提升多少决策效率？

当然，这种场景一个比较大的问题是：AI模拟人类，能准吗？答案是：比你想象的准得多。

关注微信

图片来源：Nano Banana

近期，外媒Naavik撰文称，有多项学术研究专门验证这件事。结论出人意料——LLM（**中大型语言模型**）在**预测人类行为这件事上，准确率可以达到85%以上**。不过，研究者还做了个对比测试：让同一批人类两周后再做一遍同样的问卷，他们自己的准确率只有81%。

也就是说，在某些场景下，AI比你更了解“人类平均会怎么选”。这听起来有点反直觉，但逻辑其实不复杂。人类做问卷会受情绪、环境、当下状态影响，今天心情好选了“满意”，两周后可能就选了“一般”。AI没有这些干扰，它只是根据学到的人类行为模式给出最可能的答案。

以下是Gamelook编译naavik的完整内容：

关于生成式AI对游戏行业影响的争论，它究竟是一场革命、一场灾难，还是介于两者之间？这些争论大多集中在生产端：编程、美术、音乐和营销素材创作。

然而，大型语言模型（LLM）还有一个较少被关注的应用方向，那就是消费者研究。近期有多项研究尝试利用LLM中积累的海量数据来模拟人类行为，以期大幅降低市场调研成本。相关研



最新资讯

• 超40个项目发布之外，腾讯游戏的发布会还在发什么？

• 网易再添王牌《诡影藏锋》“古风打一切”！腾讯：你又又来了这招？

• 海外全球发布！莉莉丝新游戏《Clash of Critters》“换配方”，要杀入这个百亿赛道！

• 微信杨静怡：IAP小游戏MAU3亿，SLG和MMO稳健，模拟收入增200%二合70%

• 微信李卿：小游戏月活用户破5亿，日均时长超1小时，已跑通iOS支付

• 又肝又氪！新游《坦克世界: HEAT》Steam差评如潮，Wargaming翻车了？

• 微信翁裕途：IAA小游戏MAU 4亿、70%玩家只玩IAA，收入增长30%

• 微信孟令刚：PC小游戏付费用户ARPU增长130%，在线时长增长100%

标签云

zynga

网易

Sensor T...

任天堂

小游戏

Supercell

ios

facebook

EA

日本

财报

腾讯

韩国

苹果

steam

qq

盛大

电竞

暴雪

微软

手游

dena

Android

米哈游

AI

畅游

VR

独立游戏

游族

完美

究包括：

《大型语言模型用于市场研究：数据增强方法》

《用LLM模拟人类行为的挑战：因果推断视角》

《深度生成模型合成数据的去偏方法》

《1000人生成式智能体模拟》

《LLM通过语义相似度引导李克特量表评分复现人类购买意向》

研究结果喜忧参半。LLM确实能在相当程度上复现人类的回答，但也容易产生偏差，或给出过于“安全”的中庸答案。针对这一问题，研究者们已经开发出一些新方法以确保结果更接近真实的人类反应。虽然这些研究目前尚未得到广泛应用，但对于游戏团队来说，已经出现了一些可以付诸实践的具体用途。


本文将介绍其中两篇论文，分别说明各自的研究内容和结论，再谈谈如何把这些研究成果落地用起来。

本文涉及的两篇论文分别是：《1000人生成式智能体模拟》（2024）以及《LLM通过语义相似度引导李克特量表评分复现人类购买意向》（2025）。

一、1000人生成式智能体模拟

这篇论文的研究者对1052名真实人物的态度与行为进行了数字化“克隆”，目的是了解“一批多样化的个体对新公共卫生政策和信息的反应、对产品发布的态度，以及对重大冲击事件的回应”。

研究者采用了一种新颖的方法。他们没有用人口统计信息或人设描述来提示LLM，而是进行了时长约两小时的语音访谈，并将生成的访谈文字记录作为AI智能体的记忆素材。



访谈问题基于斯坦福大学的“美国人之声”项目，内容开放、范围宽泛，例如：“请讲讲你的人生故事——从童年、求学经历，到家庭与感情，以及你经历过的重要人生事件。”

研究假设是：这些丰富的人生经历数据能让智能体准确预测真实的行为反应。研究者还加入了一个名为“专家反思”的环节。他们利用访谈文字记录，指示LLM分别扮演心理学家、行为经济学家、政治学家和人口学家等领域专家，并生成相应的反思分析。智能体在回答问题时，会从记忆中检索最相关的专家意见作为参考。

研究者随后将这些智能体的表现与真实人类参与者在问卷调查、人格测试和经济博弈中的表现进行了比对。


结果如何？

问卷回答：归一化准确率85%

大五人格特征：归一化相关性80%

经济博弈：归一化相关性66%

“归一化”意味着结果是以人类基准为参照进行评分的。值得注意的是，人类自己在两周后重做同一份问卷时，准确率也只有81%。



图表：《1000人生成式模拟》

结果表明，与仅使用人口统计信息或人设描述相比，访谈记录能大幅提升复现准确率，但这一提升在经济博弈环节不那么明显。这是合理的，因为访谈问题聚焦的是人生经历和价值观，而非具体的类博弈行为。

总体而言，这项研究最核心的发现是：用人类的访谈记录为LLM构建丰富的记忆库，能够显著提高其预测人类反应的准确性。

这对游戏消费者研究有什么用？设想一下：对玩家进行游戏方式、喜好和消费习惯方面的访谈，你就能建立一个“智能体玩家”库，用来快速验证游戏设计决策、营销思路和品牌方向。

当然，这需要建立一套商业模式来确保数据提供者获得合理、合乎伦理的补偿，但前景值得期待。这套方法会取代真人焦点小组和消费者调研吗？当然不会，但它可以在早期就给团队发出预警信号：提示方向可能走偏了。

二、LLM复现人类购买意向


这篇论文探讨了LLM能否通过预测购买意向来充当“合成消费者”。过去的做法是让LLM在1到5的李克特量表上对产品打分（即用五个选项衡量对某一陈述的同意程度，例如从“非常不同意”到“非常同意”），但这往往导致LLM给出安全的中间分数——3分，无法反映真实人群中出现的1分和5分。

为了解决这个问题，研究者开发了一种叫做“语义相似度评分”（SSR）的方法。他们不再要求LLM输出数字，而是给LLM一个带有人口统计特征的消费者人设和一个产品概念，然后让它用自然语言表达购买意向。

然而，把自然语言回答映射到1到5的李克特量表并不容易。比如这样一句话——“我大概会买。我喜欢它操作简单，可以随身携带，价格也还算合适”——很难清晰区分它究竟对应4分还是5分的购买意向。

为此，研究者采用了三步流程：


- 1.制作参考语句，分别对应李克特量表上的1到5分。例如，1分对应“我不太可能购买”，5分对应“我非常有可能购买”。
- 2.用AI模型将文字映射到多维语义空间，语义相似的文本在空间中距离更近。




图片来源：Amazon

3.计算AI消费者的回答与五条参考语句的距离。回答越接近哪条参考语句，就越倾向于对应那个评分。

研究者根据年龄、性别、收入、族裔等属性生成了合成消费者，再将AI的回答与来自57项真实消费者调研的购买意向数据进行比对。




研究人员生成了具有年龄、性别、收入和种族等属性的合成消费者。然后，他们将AI的回应与57份真实消费者购买意向调查的数据进行了比较。



结果相当可观。SSR在概念排名上达到了理论最大准确率的90%以上。换言之，AI面板与真实人类数据的相关性，几乎与随机抽取的两组人类样本之间的相关性一样高。同时，SSR解决了LLM长期存在的“分布集中”问题（即LLM总是倾向于选3），其回答分布与真实人类的回答分布高度吻合。

这套方法还有一个额外的好处。由于合成消费者生成的是自然语言，因此提供了详细的理由说明。相比之下，真实人类往往只留下“挺好的”这类简短评论，而合成人设则会具体指出对价格或品牌信任度的顾虑。



图表术语说明：

DLR（直接李克特评分）：直接提示AI对购买意向打1-5分。

FLR（后续李克特评分）：先提示AI给出文字回答，再由另一个AI（被要求扮演李克特分析专家）将回答映射为数字。

SSR（语义相似度评分）：本论文所用方法。

一项关键发现是：当结果按年龄和收入分组时，真实数据与合成数据的相似度较高，但按性别和地域分组时则不那么一致。

总体而言，这套方法前景很好。如果能用来测试应用商店截图、应用图标、用户获取素材等内容，会帮团队省下大笔费用，也让更多的实验成为可能。对小团队来说，这降低了实验门槛，将实验成本从数百上千美元压缩到个位数或两位数（基于我们自己的测试估算）。

三、针对游戏的研究复现

虽然无法完全按学术标准复现这些研究，但已有几种可用的资源：


- 1.《人类模拟》论文的作者建立了一个智能体库（Agent Bank），通过仅限API的方式开放智能体行为访问，以保护智能体所依据的真实人物免遭潜在恶意使用。
- 2.SSR论文的作者在GitHub上以MIT协议开源了SSR方法的Python实现。
- 3.LILA Games的Joseph Kim专门为游戏开发了SSR论文的网页工具版本。

本文选用第三种资源，因为它是一个已经实现SSR论文的完整功能网站。但我们怎么知道结果是否真的准确？


验证方法如下：

- 1.通过与Sensor Tower数据对比，测试其预测下载量表现的能力。
- 2.将合成回答与真实人类反馈进行比较。

第一项测试中，我们从应用商店下载量的第95、50、10百分位中各抽取两款三消游戏（共六款），以避免选到LLM训练数据中可能过度收录的“知名”游戏。



随后取每款游戏在应用商店的前三张截图，如下所示。



然后使用该网页工具，基于平台提供的玩家人设生成结果：

Sarah（休闲解谜玩家）


Alex（元游戏优化玩家）

Maria（故事完成型玩家）


Mike（午休时间玩家）

Linda（社交互动玩家）

测试结果如下：



下表对比了真实排名与合成排名，以及两者之间的名次差异。



结果方向基本正确：两款游戏排名完全吻合，两款互换了位置，剩余两款偏差在两名以内。实际上，如果在真实的A/B测试中选取合成排名前三的游戏，完全可以覆盖到真实表现最好的那些游戏。

第二项测试中，LILA Games慷慨分享了一项近期实验的结果。该团队想了解哪款应用图标更能促进玩家下载。实验涉及22个应用商店图标，针对15个自定义人设进行了调研。

与此同时，他们也通过Google Play的A/B测试对这些图标进行了实测，结果发现A/B测试的最终胜出图标与合成测试中排名第一的图标完全一致。

结论

从我们的测试来看，LLM在为游戏概念和素材提供早期信号方面展现出相当大的潜力。不过这个领域还很新，更好的方法还在不断涌现，我们自己也已经摸索出一些能优化回答质量的技术：

人设的写法直接影响反馈质量，细微的措辞差异可能带来截然不同的结果。

选择哪些人设来测试概念，同样会影响最终结果——现实中的用户研究也是如此。

不同模型（比如Gemini和ChatGPT）会给出不同的结果，最好先针对某一模型做校准，然后固定使用它。

LLM能不能加入游戏研究的工具箱？可以，但有前提。它们更适合在早期提供方向性参考，而不是最终验证。准确性也取决于具体方法——比如有研究表明，“解盲”AI（即向其说明实验设计，而不仅仅让它扮演消费者）能提高预测效果。

类似的优化还有很多，这确实是一个充满活力、持续演进的领域。

如若转载，请注明出处：<http://www.gamelook.com.cn/2026/04/591775/>

AI

LLM

用户研究

相关推荐

- [想把AI关进笼子里？千名科技人士发起...](#)
- [Supercell投资AI游戏公司：阿里“元境”...](#)
- [Lofter社区引入AI绘图工具引发轩然大...](#)
- [韩国游戏巨头NCsoft发布AI大模型VAR...](#)
- [强强联合打造 AI 游戏引擎，“AI+游戏”...](#)
- [Zynga总监：除了做智能NPC，如何在...](#)
- [喜迎曙光！游族网络单季净利润破1亿...](#)
- [AI的时代！2025年全球风险投资达5120...](#)